

1 STROJNO UCENJE

1.1 EVALVIRANJE HIPOTEZ

Pomembni kriteriji:

- **konsistentnost** hipotez z primeri (ucnimi)
- **splosnost** (tocnost za nevidene primere)
- **razumljivost** hipotez

TP=true positive, TN=true negative, FP=false positive (napaka 1. tipa), FN=false negative (napaka 2. tipa)

Klasifikacijska tocnost = $\frac{TP+TN}{TP+TN+FP+FN} = \frac{TP+TN}{N}$

Obcutljivost/senzitivnost = $TPR = \frac{TP}{TP+FN}$

1.1.1 BINARIZACIJA ATRIBUTOV

Alternativa za reševanje problematike z vecvrednostnimi atributi: **Strategije** (za primer B = [Y, G, R, B]):

- **[[Y],[R, G, B]]** (one-vs-all)
- **[[Y,R],[G,B]]**
- **vpejvaja** binarnih atributov za vsako barvo

Primer B = [Y, G, R], konstruiramo 3 nove binarne attribute:

barva	Y	G	R
Y	1	0	0
G	0	1	0
R	0	0	1

Prednost: manjše vejanje drevesa.

1.2 GRADNJA ODLOČITVENIH DREVES

Drevo gradimo tako da v vsakem koraku izberemo atribut, ki največ zmanjša entropijo (ima največji informacijski prispevek).

Rezidualna entropija (najbolši atribut -> najnižja)

$H_{rez}(A) = - \sum p(A=a_i) \sum_{c_i \in C} p(C=c_i | A=a_i) \log_2 p(C=c_i | A=a_i)$

$c_i | A=a_i$

Informacijski prispevek (najbolši atribut maksimizira)

$Gain(A) = H(Class) - H_{rez}(A)$

Razmerje informacijskega prispevka atributa A:

$IGR(A) = \frac{Gain(A)}{H(A)}$

Podana je učna množica primerov, ki je prikazana v tabeli (vreme in pritisk sta atributa, glavobol pa je razred). Naloge:

- 1) [8] Zgraditi odločitveno drevo, pri čemer za ocenjevanje atributov uporabiti informacijski prispevek. V primeru enakega števila primerov – predstavnikov obeh razredov – naj vozlišča klasificira v večinski razred iz učne množice.

$H(G) = -\frac{5}{9} \log_2 \frac{5}{9} - \frac{4}{9} \log_2 \frac{4}{9} = -0.991$

$H_{rez}(V) = \frac{3}{9} (H(1/3, 2/3)) + \frac{6}{9} (H(4/6, 2/6)) = -0.918$

$H_{rez}(P) = \frac{2}{9} (H(1/4, 3/4)) + \frac{7}{9} (H(2/3, 1/3)) + \frac{2}{9} (H(1/2, 1/2)) = 0.89$

$H_{rez}(P) < H_{rez}(V) \rightarrow$ Pritisk je najboljši atribut z njim naprej delimo...

1.2.1 TDIDT (TOP DOWN INDUCTION DECISION TREE) ALGORITHM

Pozresen algoritem, ki **lokalno** izbira najbolši atribut. - kratkoviden algoritem

Nizek pritisk nismo delili naprej, saj nimamo nobenega primera ki bi imel nizek pritisk in nizko vreme (samo sončno). Če bi delili bi dobili razreda sončno: [3, 1] in dezewno: [0, 0] kar nebi imelo smisla.

1.3 UCENJE IZ SUMNIH PODATKOV (REZANJE)

Ucna množico razbijemo na: 70% za gradnjo, 30% za rezanje. **Z rezanjem** odstranimo poddrevesa, ki niso kritična in so redundantna tako zmanjšamo velikost drevesa.

tocnost t...verjetnost pravilnosti klasifikacije

napaka $e \dots 1 - t$

relativna frekvenca $p = \frac{N}{N}$


m-ocena $p = \frac{n+p \cdot m}{N+m}$

m... koliko zaupam apriorni verjetnosti

p_A apriorna verjetnost (pove domenski ekspert) (v našem primeru relativna frekvenca)

Laplacova ocena verjetnosti $p = \frac{n+1}{N+k}$

k...stevilo vseh možnih razredov



Primer z (Laplace)

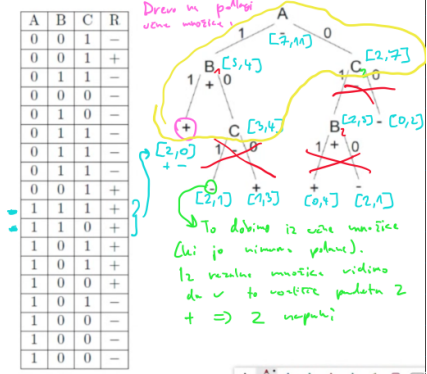
$e_L(d) = 1 - t = 1 - \frac{13+1}{20+2} = 0.363$

$E_L(d) = \frac{12}{20} \cdot e_L(d_1) + \frac{8}{20} \cdot e_L(d_2) = \frac{12}{20} \cdot (1 - \frac{7+1}{12+2}) + \frac{8}{20} (1 - \frac{13+1}{20+2})$

1.3.2 REP (REDUCED ERROR PRUNNING)

G(v)=st. napacnih klasifikacij v poddrevesu - st. napacnih klasifikacij v korenju poddrevesa

$G(v) \geq 0 \Rightarrow$ rezemo poddrevo



$e(C) = 3, e_T = 2 + 3 = 5, G(C) = 5 - 3 = 2 \geq 0 \rightarrow$ rezemo

1.4 OČENJEVANJE USPEŠNOSTI MODELOV

tocnost t... verjetnost pravilnosti klasifikacije

Laplacova ocena verjetnosti $p = \frac{n+1}{N+k}$


k...stevilo vseh možnih razredov

list.

$L1=[a,a,b], L2=[a,b,b,b,c,c], L3=[c,c]$

$t_{L1} = \frac{2+1}{3+3} = 0.5, t_{L2} = \frac{4+1}{7+3} = 0.5, t_{L3} = \frac{2+1}{2+3} = 0.6$

tocnost drevesa: $t_D = 3/12 \cdot 0.5 + 7/12 \cdot 0.5 + 2/12 \cdot 0.6 = 0.5167$



$e = 1 - (P(B=0)P(R=0|B=0) + P(B=1)P(R=1|B=1))$

1.5 OBRAVNAVNA MANKAJOČIH ATRIBUTOV, NAVINAI BAYESOV KLASIFIKATOR

1.5.1 NAIVNI BAYES

Ce poznamo razred, kam klasificiramo ce nepoznamo atributov:

Klasifikator: $\text{argmax}_{C \in C} P(C) \prod_{i=1}^n P(x_i | C)$

C...razred, x_i ...atributi

Verjetnosti:

$P(C=c | x_1, \dots, x_n) = \frac{P(C=c)P(X_1=x_1|C=c)P(X_2=x_2|C=c) \dots}{P(X_1=x_1)P(X_2=x_2) \dots}$

Primer pritisk, vreme, razred glavobol

X\Y	ne	da
P(G)	P(G=ne) = 5/9	P(G=da) = 4/9
P(P=srednji)	P(P=sred ne) = 1/5	P(P=sred da) = 2/4
P(V=dezevno)	P(V=dez G=ne) = 1/5	P(V=dez G=da) = 2/4
$P(y) = \prod_{i=1}^n P(x_i y)$	5/9 · 1/5 · 1/5	4/9 · 2/4 · 2/4


1.5.2 NOMOGRAMI

Ciljni razred $C = c_T$


$Xx_i = x_j = \ln \left(\frac{P(C=c_T | X_i=x_j)}{\frac{P(C=c_T)}{P(C=c_T)}} \right)$

PRIMER: Napisi nomogram za verjetnostno razlago modela za klasificiranje v razred **boleznen**=da

		boleznen	
		DA	NE
družina	da	200	150
	ne	120	110
spol	moški	140	160
	ženska	180	100



Da ima oseba **boleznen** najbolj pripomoreta, da je oseba **zemska** in ima družino.



1.7 REGRESIJA

Ucni primeri so podani/oznaceni kot vrednosti vhodov in izhodov. $(\vec{x}_1, \vec{y}_1), (\vec{x}_2, \vec{y}_2), \dots, (\vec{x}_N, \vec{y}_N)$

\vec{x}_i ... atributi, \vec{y}_i ... ciljna spremenljivka

Locimo dve vrsti problemov:

1. **Klasifikacijski problemi** - y_j diskretna
2. **Regresijski problemi** - y_j zvezna

1.7.1 LOKALNO UTEŽENA REGRESIJA

$h(\vec{x}_2) = \frac{\sum_{i=1}^k w_i f(\vec{x}_i)}{\sum_{i=1}^k w_i}, w_i(\dots) \text{utez}$

Z lokalno uteženo regresijo želimo napovedati dolžino potov 2 atributov $x_1 = (A=1, B=2, C=1)$. Pri izračunu uporabi:

- Manhattanovo razdaljo za merjenje razdalj.
- Jedrno funkcijo $w_i = \frac{1}{d_i^2}$.

1.7.2 REGRESIJSKA DREVEJA

Linearna regresija je poseben primer regresijskega drevesa. V listih regresijskega drevesa včasih napovemo kar povprečno vrednost.

1.8 UNSUPERVISED LEARNING

Ucni primeri niso oznaceni (nimajo ciljne spremenljivke), ucimo se vzorcev v podatkih, (npr. gručenje)

1.8.1 HIERARHIČNO GRUČENJE

Poveže po podobnosti med primeri, primer zacne kot samostojna gruca, na koncu vsi primeri pripadajo eni gruci


Dendrogram: drevo, ki predstavlja gručenje

Single-linkage: povezava med grucami je najkrajša razdalje med primeroma iz različnih gruc.

Complete-linkage: najdaljša razdalja med primeroma iz različnih gruc.

Average-linkage: povprečna razdalja med primeroma iz različnih gruc.

Tocke A(3,1), B(1,2), C(3,4), D(5,2), E(1,1), manhattan, complete linkage:



1.8.2 K-MEANS

1. V prostor dodamo k centroidov, ki predstavljajo gruce.
2. Izračunamo ketri centroidi je najbližji vsakemu primeru.
3. Izračunamo nove centre gruc = $\frac{1}{|G|} \sum_{i \in G} x_i$
4. Ponovimo korake 2 in 3 dokler se centri ne premaknejo.

V množici točk A(3,1), B(1,2), C(3,4), D(5,2), E(1,1), manhattanška razdalja, začetni vrednosti centroidov C1(4,4) in C2(5,4).

Tocka	d(X,C1)	d(X,C2)	Gruca
A	4	5	C1
B	5	6	C1
C	1	2	C2
D	3	2	C2
E	6	7	C1

V naslednji iteraciji sta koordinati centroidov:

$C1 = (\frac{3+1+3+1}{4}, \frac{1+2+4+1}{4}) = (2, 2)$ in $C2 = D = (5, 2) \dots$

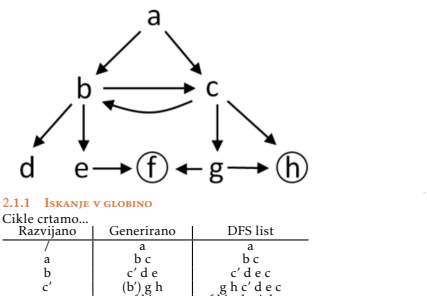
1.9 SPODBUJEVALNO UCENJE - REINFORCEMENT LEARNING

Inteligentni agent se uci iz zaporedja nagrad in kazni

1.10 OČENJEVANJE UCENJA

k-fold, celo ucno množico razbij na k disjunktih podmnožic za vsako od k podmnožic uporabi množico kot testno množico, preostalih k-1 množic kot ucno množico.

2 PREISKOVANJE



2.1.1 ISKANJE V GLOBINO

Cikle crtamo...	Generirano	DFS list
/		
a	a	a
b	b	a b c
c	c	c d e c
d	d	b c d e c
e	e	f b g h c d e c
f	f	končno
g	g	končno

Izboljšave (Iskanje s sestopanjem, iterativno poglabljanje)

2.1.2 ISKANJE V SIRINO

Razvijano	Generirano	Vrsta
a	b c	[b, c]
b	c d e	[c, d, e]
c	b g h	[c, d, e, b, g, h]
d	b g h	[c, d, e, b, g, h]
e	b g h	[c, d, e, b, g, h]
f	b g h	[c, d, e, b, g, h]
g	končno	končno

2.1.3 ITERATIVNO POGLABLJANJE

problem globinsko omejenega iskanja -> nastavitev meje 1 Mejo 1 postopoma povečujemo za 1, dokler ne najdemo rešitve.

- **popolnost:** Da
- **optimalnost:** Da
- **casovna zahtevnost** $O(b^d)$
- **prostorska zahtevnost** $O(bd)$


Boljše od iskanja v globino/sirino

2.1.4 DVOSMERNO ISKANJE

Poznemo vzporedni iskanji od zacetka do cilja in od cilja do zacetka.

Implementacija dvosmernega iskanja:

- ciljno vozlišče mora biti znano
- originalni problemski prostor preslikamo v dvosmerni prosto stanj E1, E2 dosegljiv iz S1, S2, S3 dosegljiv iz S(E) -> (S1, E1), (S1, E2), (S2, E1), (S2, E2)...
- Vozlišče (S1, E1) je v (dvosmernem) prostoru cilja
- Vozlišče se veča E-S od zacetka dolzina na isto mesto pridemo iz obeh strani) ali S->E (liha pot sosednja)



2.1.5 PRIMERJAVE ALGORITMOV

Kriterij	Iskanje v širino	Iskanje v globino	Iskanje z omejitvijo globline	Iterativno poglabljanje	Dvosmerno iskanje
Popolnost	Da (vsaj enkrat)	Ne	Ne	Da (vsaj enkrat)	Da
Optimalnost	Da (vsaj enkrat)	Ne	Ne	Da (vsaj enkrat)	Da
Čas. zahtevnost	$O(b^d)$	$O(b^m)$	$O(b^d)$	$O(b^d)$	$O(b^{d/2})$
Prost. zahtevnost	$O(b^d)$	$O(bm)$	$O(bd)$	$O(bd)$	$O(b^{d/2})$

2.2 INFORMIRANI PREISKOVALNI ALGORITMI

Ideja: preiskovanje usmerjamo z dodatnim znanjem **hevrstiko** (ocenitvena funkcija za obetavnost vozlišca)


- **optimistina/dopustna:** $\forall n: h(n) \leq h^*(n)$ (h^* je optimalna ocena)
- **optimalna:** $h(n) = h^*(n)$
- **pesimistina:** $h(n) \geq h^*(n)$

2.2.1 A*

A* is informed version of **dijkstra** (uses heuristics and pq), ce h(dopustna)=**popolna in optimalna**

Casovna zahtevnost odvisna od hevrstike: $E = (h^* - h)/h^*, O(b^{E \cdot d})$, b-stopnja vejanja, d-globina optimalne rešitve

Prostorska zahtevnost problem (hrani vsa vozlišca v spominu)



2.2.2 IDA* (ITERATIVE DEEPENING A*)

$f(n) = g(n) + h(n)$, $g(n)$ =cena do vozlišca, $h(n)$ hevrstika

Razvijamo dokler ne pridemo do ciljnega vozlišca

X	a	b	c	d	e	f	g	h
h(X)	4	6	2	6	3	0	7	0

Razvijano | Generirana | Priority Queue

/ | a(4) | |

a | b(7) c(6) | [c(6), b(7)]

c | b(11) g(12) h(8) | [b(7), h(8), b(11), g(12)]

b | c(4) d(8) e(5) | [c(4), e(5), h(8), d(8), b(11), g(12)]

...

2.2.3 KAKOVOST HEVRISTIČNIH FUNKCIJ

Kakovost h ocenimo z **številom generiranih vozlišcev** ter **efektivnim faktorjem vejanja** (N vozlišce je algoritem general da je na globini d nasel rešitev)

Hocemo imeti dopustne hevrstike s **cim višjimi vrednostmi in sprejemljivo ceno** (casom izracuna)

Ce $h_2(n) \geq h_1(n), \forall n$ potem h_2 dominira h_1

2.3 NEDETERMINISTIČNO OKOLJE

Pomaga reševati probleme z **dekompozicijo** na manjše probleme

Uporabnost:

- princip deli in vladaj
- iskanje v nedeterminističnih okoljih
- igre med dveema nasprotnikoma s popolno informacijo (sah, dama)
- ekspertno reševanje problemov

2.3.1 AO*

- posplošitev A* na grafe AND/OR
- **popoln in optimalen** \Leftrightarrow h(n) ne precenjuje dejanske cene do cilja

F(N) ocena za usmerjanje preiskovanja, $H(N)$ dinamicna hevrsticina ocena

Postopek:

1. Razvij najcenejše vozlišče
 - ce list in končno (oznaci), preveri 3. korak, nadaluj v 1.
 - ce list in ni končno (oznaci) vrednost vozlišca = ∞
2. Posodobimo vse predhodnike
 - v AND starših, cena starša = min(sinov) + povezava v
 - v OR starših, cena starša = max(sinov) + povezava v
3. Končaj ko obstaja pot od zacetnega vozlišca, po kateri v AND vozlišcih po vseh sinovih prides do cilja, v OR vozlišcih v vsaj enem

