

1 STROJNO UCENJE

1.1 EVALVIRANJE HIPOTEZ

Pomembni kriteriji:

- **konsistentnost** hipotez z primeri (ucnimi)
- **splosnost** (tocnost za nevidene primere)
- **razumljivost** hipotez

TP=true positive, TN=true negative, FP=false positive (napaka 1. tipa), FN=false negative (napaka 2. tipa)

Klasifikacijska tocnost = $\frac{TP+TN}{N}$

Obcutljivost/senzitivnost = $TPR = \frac{TP}{TP+FN}$

1.1.1 BINARIZACIJA ATRIBUTOV

Aleternativa za reševanje problematike z vecvrednostnimi atributi:

Strategije (za primer B = [Y, G, R, B]):

- $\{[Y], [R, G, B]\}$ (one-vs-all)
- $\{[Y, R], [G, B]\}$
- "vpeljava binarnih atributov za vsako barvo"

Primer B = [Y, G, R], konstruiramo 3 nove binarne atribute:

barva	Y	G	R
Y	1	0	0
G	0	1	0
R	0	0	1

Prednost: manjše vejanje drevesa.

1.2 GRADNJA ODLOČITVENIH DREVES

Drevo gradimo tako da v vsakem koraku izberemo atribut, ki največ zmanjša entropijo (ima največ informacijski prispevek).

Rezidualna entropija (najbolši atribut > najnižja)

$H_{rez}(A) = - \sum p(A=a_i) \cdot \sum p(C=c_j|A=a_i) \log_2 p(C=c_j|A=a_i)$

$c_j|A=a_i$

Informacijski prispevek (najbolši atribut maksimizira)

$Gain(A) = H(Class) - H_{rez}(A)$

Razmerje informacijskega prispevka atributa A:

$IGR(A) = \frac{Gain(A)}{H(A)}$

Podana je učna množica primerov, ki je prikazana v tabeli (vreme in pritisk sta atributa, glavobol pa je razred). Naloge:

- a) [10] Zgraditi odločitveno drevo, pri čemer za ocenjevanje atributov uporabiti informacijski prispevek. V primeru enakega števila primerov – predstavnikov obeh razredov – naj vozilce klasificira v večinski razred iz učne množice.

$H(G) = -\frac{5}{9} \log_2 \frac{5}{9} - \frac{4}{9} \log_2 \frac{4}{9} = -0.991$

$H_{rez}(V) = \frac{3}{9} (H(1/3, 2/3)) + \frac{6}{9} (H(4/6, 2/6)) = -0.918$

$H_{rez}(P) = \frac{2}{9} (H(1/4, 3/4)) + \frac{3}{9} (H(2/3, 1/3)) + \frac{2}{9} (H(1/2, 1/2)) = 0.89$

$H_{rez}(P) < H_{rez}(V) \rightarrow$ Pritisk je najboljši atribut z njim naprej delimo...

1.2.1 TDIDT (TOP DOWN INDUCTION DECISION TREE) ALGORITHM

Pozresen algoritem, ki lokalno izbira najbolši atribut.

- kratkoviden algoritem

Nizek pritisk nismo delili naprej, saj nimamo nobenega primera ki bi imel nizek pritisk in deževno vreme (samo sončno). Če bi delili bi dobili razreda sončno: [3, 1] in deževno: [0, 0] kar nebi imelo smisla.

1.3 UCENJE IZ SUMNIH PODATKOV (REZANJE)

Ucna množico razbijemo na: 70% za gradnjo, 30% za rezanje. Z rezanjem odstranimo poddrevesa, ki niso kritična in so redundantna tako zmanjšamo velikost drevesa.

točnost 1-t-verjetnost pravilnosti klasifikacije

napaka $e \dots 1-t$

relativna frekvenca $p = \frac{N}{N}$

m-ocena $p = \frac{n+pa \cdot m}{N+m}$

m... koliko zaupam apriorni verjetnosti

pa apriorna verjetnost (pove domenski ekspert) (v našem primeru relativna frekvenca)

Laplacova ocena verjetnosti $p = \frac{n+1}{N+k}$

k...stevilo vseh možnih razredov

1.3.1 MEP (MINIMAL ERROR PRUNNING)

e =staticna napaka, E =vzvrtna napaka, $e \leq E \rightarrow$ rezemo poddrevo

Primer z (Laplace)

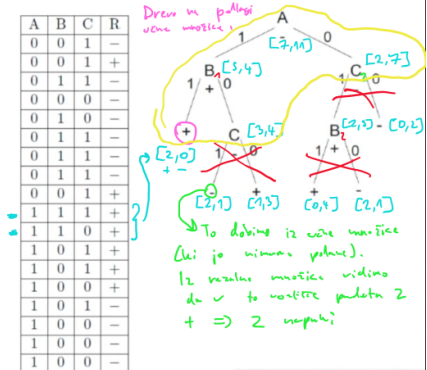
$e_L(d) = 1 - t = 1 - \frac{13+1}{20+2} = 0.363$

$E_L(d) = \frac{12}{20} \cdot e_L(d_1) + \frac{8}{20} \cdot e_L(d_4) = \frac{12}{20} \cdot (1 - \frac{7+1}{12+2}) + \frac{8}{20} \cdot (1 - \frac{13+1}{20+2})$

1.3.2 REP (REDUCED ERROR PRUNNING)

G(v)=st. napacnih klasifikacij v poddrevesu - st. napacnih klasifikacij v korenju poddrevesa

$G(v) \geq 0 \Rightarrow$ rezemo poddrevo



$e(C) = 3, e_T = 2 + 3 = 5, G(C) = 5 - 3 = 2 \geq 0 \rightarrow$ rezemo

1.4 OČENJEVANJE USPEŠNOSTI MODELOV

točnost t... verjetnost pravilnosti klasifikacije

Laplacova ocena verjetnosti $p = \frac{n+1}{N+k}$


k...stevilo vseh možnih razredov

list.

$L1=[a,a,b], L2=[a,b,b,b,b,c,c], L3=[c,c,c]$

$t_{L1} = \frac{2+1}{3+3} = 0.5, t_{L2} = \frac{4+1}{7+3} = 0.5, t_{L3} = \frac{2+1}{2+3} = 0.6$

točnost drevesa: $t_D = 3/12 \cdot 0.5 + 7/12 \cdot 0.5 + 2/12 \cdot 0.6 = 0.5167$



$e = 1 - (P(B=0)P(R=0|B=0) + P(B=1)P(R=1|B=1))$

1.5 OBRAVNAVNA MANKAJOČIH ATRIBUTOV, NAVINII BAYESOV KLASIFIKATOR

1.5.1 NAIVNI BAYES

Če poznamo razred, kam klasificiramo ce nepoznamo atributov:

Klasifikator: $\text{argmax}_{C \in C} P(C) \prod_{i=1}^n P(x_i|C)$

Verjetnost:

$C \dots$ razred, $x_i \dots$ atributi

$P(C = c|x_1, \dots, x_n) = \frac{P(C=c)P(X_1=x_1|C=c)P(X_2=x_2|C=c) \dots P(X_N=x_N|C=c)}{P(X_1=x_1)P(X_2=x_2) \dots P(X_N=x_N)}$

Primer pritisk, vreme, razred glavobol

X\Y	ne	da
P(G)	P(G=ne) = 5/9	P(G=da) = 4/9
P(P=srednji)	P(P=sre G=ne)=1/5	P(P=sre G=da)=2/4
P(V=dezevno)	P(V=dez G=ne)=1/5	P(V=dez G=da)=2/4
$P(y) = \prod_{i=1}^n P(x_i y)$	5/9 · 1/5 · 1/5	4/9 · 2/4 · 2/4

1.5.2 NOMOGRAMI

Ciljni razred $C = c_T$

$Xx_j = x_j = \ln \left(\frac{P(C=c_T|X_i=x_j)}{P(C=c_T)} \cdot \frac{P(C=c_T)}{P(C=c_T)} \right)$

Napisni nomogram za verjetnostno razlogo modela za klasificiranje v razred bolezen=da

$X_D = da = \ln \left(\frac{200}{150} \cdot \frac{150}{260} \right) = 0.08$

$X_D = ne = -0.121$

$X_S = m = -0.341$

$X_S = z = 0.380$

moški ženska SPOL

ne da DRUŽINA

bolezen

DA NE

družina

da 200 150

ne 120 110

spol

moški 140 160

ženska 180 100

Da ima oseba bolezen najbolj pripomoreta, da je oseba ženska in ima družino.

1.6 K-NAJBЛИЖИХ SOSEDOV

Učni primeri so podani/označeni kot vrednosti vhodov in izhodov. $(\vec{x}_1, \vec{y}_1), (\vec{x}_2, \vec{y}_2), \dots, (\vec{x}_N, \vec{y}_N)$

$\vec{x}_i \dots$ atributi, $\vec{y}_i \dots$ ciljna spremenljivka

Locimo dve vrsti problemov:

1. Klasifikacijski problemi - y_j diskretna
2. Regresijski problemi - y_j zvezna

1.7 REGRESIJA

Učni primeri so podani/označeni kot vrednosti vhodov in izhodov. $(\vec{x}_1, \vec{y}_1), (\vec{x}_2, \vec{y}_2), \dots, (\vec{x}_N, \vec{y}_N)$


$\vec{x}_i \dots$ atributi, $\vec{y}_i \dots$ ciljna spremenljivka

Locimo dve vrsti problemov:

1. Klasifikacijski problemi - y_j diskretna
2. Regresijski problemi - y_j zvezna

1.7.1 LOKALNO UTEŽENA REGRESIJA

$h(\vec{x}_i) = \frac{\sum_{j=1}^k w_i \cdot f(\vec{x}_i)}{\sum_{j=1}^k w_i}$, $w_i(d) \dots$ utež



1.7.2 REGRESIJSKA DREVEJA

Linearna regresija je poseben primer regresijskega drevesa.

V listih regresijskega drevesa včasih napovemo kar povprečno vrednost.

2.2.1 A*

A* is informed version of dijkstra (uses heuristics and pq), če h(dopustna)=popolna in optimalna

Casovna zahtevnost odvisna od hevristike: $E = (h^* - h)/h^*, O(b^{E \cdot d})$, b-stopnja vejanja, d-globina optimalne rešitve

Prostorska zahtevnost problem (hrani vsa vozilca v spominu)

1.8 UNSUPERVISED LEARNING

Učni primeri niso označeni (nimajo ciljne spremenljivke), ucimo se vzorcev v podatkih, (npr. gruenje)

1.8.1 HIERARHIČNO GRUCENJE

Poveže po podobnosti med primeri, primer zacne kot samostojna gruca, na koncu vsi primeri pripadajo eni gruci

Dendrogram: drevo, ki predstavlja gruenje.

Single-linkage: povezaava med grucami je najkrajša razdalje med primeroma iz različnih gruc.

Complete-linkage: najdaljša razdalja med primeroma iz različnih gruc.

Average-linkage: povprečna razdalja med primeroma iz različnih gruc.

Tocke A(3,1), B(1,2), C(3,4), D(5,2), E(1,1), manhattan, complete linkage:

$\begin{matrix} A & B & C & D & E \\ A & 0 & 3 & 3 & 2 \\ B & & 0 & 4 & 4 \\ C & & & 0 & 4 \\ D & & & & 0 \\ E & & & & & 0 \end{matrix} \rightarrow \begin{matrix} A & BE & C & D \\ A & 0 & 3 & 3 \\ BE & & 0 & 5 \\ C & & & 0 \\ D & & & & 0 \end{matrix} \rightarrow \begin{matrix} ABE & C & D \\ ABE & 0 & 5 \\ C & & 0 \\ D & & & 0 \end{matrix} \rightarrow \begin{matrix} ABE & CD \\ ABE & 0 \\ CD & 5 \end{matrix}$

1.8.2 K-MEANS

1. V prostor dodamo k centroidov, ki predstavljajo gruce.

2. Izračunamo ketri centroidi je najbližji vsakemu primeru.

3. Izračunamo nove centre gruc = $\frac{1}{|G|} \sum_{i \in G} x_i$

4. Ponovimo korake 2 in 3 dokler se centri ne premaknejo.

V množici točk A(3,1), B(1,2), C(3,4), D(5,2), E(1,1), manhattan, razdalja, začetni vrednosti centroidov C1(4,4) in C2(5,4).

Tocka d(X,C1) d(X,C2) Gruca

A 4 5 C1

B 1 2 C1

C 5 6 C1

D 2 2 C2

E 6 7 C1

V naslednji iteraciji sta koordinati centroidov:

$C1 = (\frac{3+1+3+1}{4}, \frac{1+2+4+1}{4}) = (2,2)$ in $C2 = D = (5,2) \dots$

1.9 SPODBUJEVALNO UCENJE - REINFORCEMENT LEARNING

Inteligentni agent se uči iz zaporedja nagrad in kazni

1.10 OČENJEVANJE UCENJA

k-fold, celo ueno množico razbij na k disjunktih podmnožic za vsako od k podmnožic uporabi množico kot testno množico, preostalih k-1 množic kot učno množico.

2 PREISKOVANJE

2.1 NEINFORMIRANI PREISKOVALNI ALGORITMI

2.1.1 ISKANJE V SIRINO

2.1.2 ISKANJE V GLOBINO

2.1.3 ITERATIVNO POGLABLJANJE

problem gobinsko omejenega iskanja -> nastavitve meje 1 Mejo 1 postopoma povečujemo za 1, dokler ne najdemo rešitve.

• popolnost: Da

• optimalnost: Da

• časovna zahtevnost $O(b^d)$

• prostorska zahtevnost $O(bd)$


Boljše od iskanja v globino/sirino

2.1.4 DVOSMERNO ISKANJE

Poznemo vzporedni iskanji od zacetka do cilja in od cilja do zacetka.

Implementacija dvosmernega iskanja:

- ciljno vozilce mora biti znano
- originalni problemski prostor preslikamo v dvosmerni prsto stanj E1 E2 dosegljiv iz E1 S2 S3 dosegljiv iz S(S,E) -> (S1, E1), (S1, E2), (S2, E1), (S2, E2)...
- Vozilce (Si, Ei) je v dvosmernem prostoru ciljo vozilce ce velja E=S (soda dolzina na isto mesto pridemo iz obeh strani) ali S>E (liha pot sosednja)



2.2 INFORMIRANI PREISKOVALNI ALGORITMI

Idea: preiskovanje usmerjamo z dodatnim znanjem hevristiko (ocenitvena funkcija za obetavnost vozilca)

- optimistna/dopustna: $\forall n: h(n) \leq h^*(n)$ (h^* je optimalna ocena)

- optimalna: $h(n) = h^*(n)$

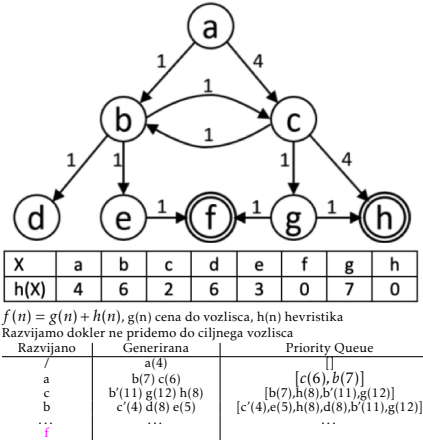
- pesimistna: $h(n) \geq h^*(n)$

2.2.1 A*

A* is informed version of dijkstra (uses heuristics and pq), če h(dopustna)=popolna in optimalna

Casovna zahtevnost odvisna od hevristike: $E = (h^* - h)/h^*, O(b^{E \cdot d})$, b-stopnja vejanja, d-globina optimalne rešitve

Prostorska zahtevnost problem (hrani vsa vozilca v spominu)



$f(n) = g(n) + h(n)$, $g(n)$ cena do vozilca, $h(n)$ hevristika

Razvijamo dokler ne pridemo do ciljnega vozilca

Razvijano	Generirana	Priority Queue
/	/	/
a	a(4)	[c(6), b(7)]
c	b(11), e(12), h(8)	[b(7), h(8), b(11), g(12)]
b	c(4), d(8), e(5)	[c(4), e(5), h(8), d(8), b(11), g(12)]
...
f	f	...

2.2.2 IDA* (ITERATIVE DEEPENING A*)

$f(n) = g(n) + h(n)$, $g(n)$ =cena poti do n

Meja	Razvijano	Generirana	DFS (list)
0	/	s(7)	/
7	/	s(7)	/
	s	a(8), b(7), c(7)	s
	b	f(6), h(5)	b, c
	f	g(7), h(9), i(11)	g, h, c
	g		

2.2.3 KAKOVOST HEVRISTICNIH FUNKCIJ

Kakovost h ocenimo z številom generiranih vozilcev ter učinkovitostjo faktorjem vejanja (N vozilcev je algoritem general da je na globini d nasel rešitev)

Hocemo imeti dopustne hevristike s cim višjimi vrednostmi in spremeljivo ceno (casom izracuna)

Ce $h_2(n) \geq h_1(n), \forall n$ potem h_2 dominira h_1

2.3 PREISKOVANJE GRAFOV AND/OR, NEDETERMINISTIČNO OKOLJE

Pomagajo reševati probleme z dekompozicijo na manjše probleme

Uporabnost:

- princip deli in vladaj
- iskanje v nedeterminističnih okoljih
- igre med dvema nasprotnikoma s popolno informacijo (sah, dama)
- ekspertno reševanje problema

2.3.1 AO*

- poslopetost A* na grafe AND/OR
- popoln in optimalen \Leftrightarrow h(n) ne preceňuje dejanske cene do cilja

F(N) ocena za usmerjanje preiskovanja, h(N) dinamicna hevristična ocena

Postopek:

1. Razvij najcenejše vozilce
 - ce list in končno (oznaci), preveri 3. korak, nadaluj v 1.
2. Posodobimo vse predhodnike
 - v AND starih, cena stara = min(sinov) + povezaava v
 - v OR starih, cena stara = min(sinov) + povezaava v
3. Končaj ko obstaja pot od zacetnega vozilca, po kateri v AND vozilcih po vseh sinovih pridemo do cilja, v OR vozilcih v vsaj enem

2.3.2 ALGORITHM MINIMAX

$O(n^d)$

2.3.3 REZANJE ALFA-BETA

V najbolšem primeru zmanjša iz $O(b^{m \cdot d})$ na $O(b^{m \cdot d/2})$

2.4 LOKALNO PREISKOVALNI ALGORITMI

plezanje na hrib, simulirano ohlajanje, gen.algoritmi...

2.4.1 LOKALNO ISKANJE V SNOPU

generiraj k naključnih zacetnih stanj iz vsakega generiraj sosedo izber k najboljših naslednikov ponavljaj (iz maksimum stohastično iskanje -> 1-verjetnost/sumvseh)

3 PLANIRANJE

plan zaporedje akcij, ki pripelje od zacetnega do koncnega stanja

3.1 PLANIRANJE S SREDSTVI IN CILJI (STRIPS)

Agentu opisemo svet in postavimo fizikalne omejitve.

Ne zagotavljamo optimalne rešitve, obravnavamo le en cilj naenkrat (ko ga dosežemo, se lahko ostali izgubijo) = Sussmanova anomalija

Akcija move(X, From, To)

• pogoj: cond=[clr(X), on(X,F), clr(T)] \rightarrow pogoji za izvajanje akcije,

• poz. učinki: add=[on(X,T), clr(F)] \rightarrow nova stanja,

• neg. učinki: dels=[on(X,F), clr(T)] \rightarrow izbrisana stanja,

• omejitve: const=[F \neq T, X \neq F, X \neq T, block(X)] \rightarrow omejitve akcij (fizikalne omejitve),

Algoritem:

1. Izberi se neresen cilj iz množice CILJEV
2. Izberi akcijo, ki izbrani cilj doda v stanje
3. Omogoči izbrano akcijo (izpolni pogoje)
4. Izvedi akcijo (ki izpolni pogoje na pogoje)
5. Če obstajajo nereseni cilji \rightarrow 1.

